


# Clasificación de Textos

# Clasificación de Textos

## Detección de spam

From: selenac.casas@sespa.es  
Reply-to: sgtclark0654@hotmail.com  
Subject: Oportunidad Única!

Tengo una propuesta comercial que podría interesarte. Notifícame si estás interesado en más detalles.




# Clasificación de Textos

## Detección de spam

From: selenac.casas@sespa.es  
Reply-to: sgtclark0654@hotmail.com  
Subject: Oportunidad Única!

Tengo una propuesta comercial que podría interesarte. **Notifícame** si estás interesado en **más detalles**.



# Clasificación de Textos


## Detección de sentimiento

@juanma25



Que **bien** que estoy!

**Empanadas + Netflix** , infalible!



# Clasificación de Textos

De que país es este tweet?

@amiguis90

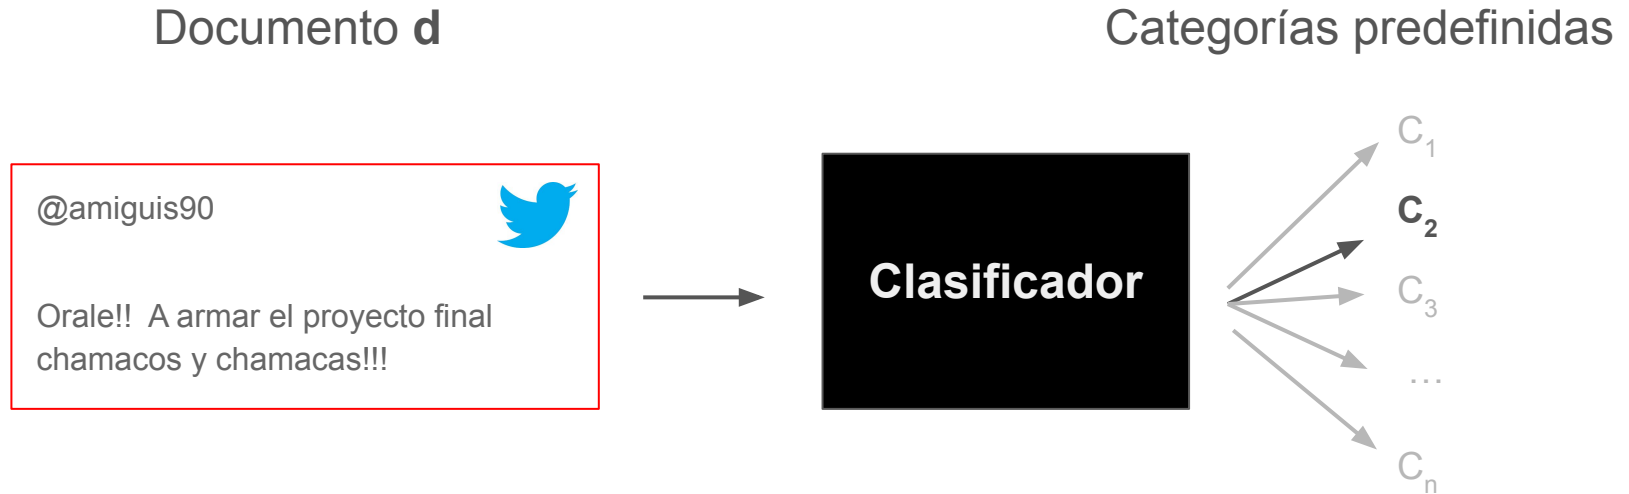


**Orale!!** A armar el proyecto final **chamacos**  
y **chamacas!!!**



# Clasificación de Textos

## Idea general




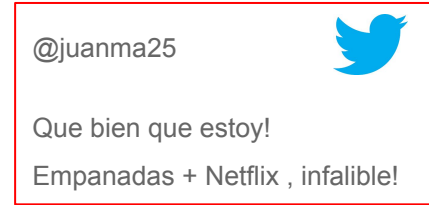
# Métodos:

## Opción 1

- Uso de reglas y expresiones regulares

## Opción 2

- Supervised Machine Learning




# Supervised Machine Learning

Input  $\longrightarrow \{ (d_1, c_1), (d_2, c_2), (d_3, c_3), \dots, (d_n, c_n) \}$




Clasificador






# Naïve Bayes

- Input  $\longrightarrow \{ (d_1, c_1), (d_2, c_2), (d_3, c_3), \dots, (d_n, c_n) \}$
- Dado un nuevo  $(d, ?)$ , estima  $P(\text{pos}|d)$  y  $P(\text{neg}|d)$



# Naïve Bayes

- Input  $\longrightarrow \{ (d_1, c_1), (d_2, c_2), (d_3, c_3), \dots, (d_n, c_n) \}$
- Dado un nuevo  $(d, ?)$ , estima  $P(\text{pos}|d)$  y  $P(\text{neg}|d)$
- Selecciona la clase de mayor probabilidad (Maximum A Posteriori)



$$c_{MAP} = \underset{c \in C = \{\text{pos}, \text{neg}\}}{\operatorname{argmax}} P(c|d)$$

# Naïve Bayes

$$c_{MAP} = \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(c|d)$$

## Teorema de Bayes

$$P(c|d) = \frac{P(d|c)P(c)}{P(d)}$$

- $P(c|d)$ : Probabilidad de que el documento  $d$  sea de la clase  $c$  (posterior)
- $P(d|c)$ : Probabilidad de obtener el documento “ $d$ ” dado que es de la clase  $c$  (likelihood)
- $P(c)$ : Probabilidad de la clase  $c$  (prior)
- $P(d)$ : Probabilidad de de obtener un documento  $d$

# Naïve Bayes

$$\begin{aligned}c_{MAP} &= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(c|d) \\&= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} \frac{P(d|c)P(c)}{P(d)}\end{aligned}$$

## Teorema de Bayes

$$P(c|d) = \frac{P(d|c)P(c)}{P(d)}$$

- $P(c|d)$ : Probabilidad de que el documento  $d$  sea de la clase  $c$  (posterior)
- $P(d|c)$ : Probabilidad de obtener el documento “ $d$ ” dado que es de la clase  $c$  (likelihood)
- $P(c)$ : Probabilidad de la clase  $c$  (prior)
- $P(d)$ : Probabilidad de de obtener un documento  $d$

# Naïve Bayes

$$c_{MAP} = \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(c|d)$$

$$= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} \frac{P(d|c)P(c)}{P(d)}$$

No depende de  $c$

$$= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(d|c)P(c)$$

## Teorema de Bayes




$$P(c|d) = \frac{P(d|c)P(c)}{P(d)}$$

- $P(c|d)$ : Probabilidad de que el documento  $d$  sea de la clase  $c$  (posterior)
- $P(d|c)$ : Probabilidad de obtener el documento “ $d$ ” dado que es de la clase  $c$  (likelihood)
- $P(c)$ : Probabilidad de la clase  $c$  (prior)
- $P(d)$ : Probabilidad de de obtener un documento  $d$

# Naïve Bayes

$$\begin{aligned}c_{MAP} &= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(d|c)P(c) \\ &= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(x_1, x_2, x_3, \dots, x_m | c)P(c)\end{aligned}$$

## Set de entrenamiento

$d_1$	@nos_paso_a_todos <b>Odio</b> al heladero! Me puso casi todo de americana!	$c_1 =$ 
$d_2$	@mary_de_recoleta Muy <b>buena</b> peliiii, Las <b>quiero</b> amiguiis!	$c_2 =$ 
...		
$d_n$	@señor_de_la_plaza76 Mi Vieja mula ya no es lo que era	$c_n =$ 

## Quiero predecir

$d$	@juanma25 Que bien que estoy!	$c_{MAP} = ?$
-----	----------------------------------	---------------

# Naïve Bayes

$$\begin{aligned} c_{MAP} &= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(d|c)P(c) \\ &= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(x_1, x_2, x_3, \dots, x_m | c)P(c) \end{aligned}$$

estimación


$$\frac{\#c}{\#D}$$



## Set de entrenamiento

$d_1$

@nos\_paso\_a\_todos  
**Odio** al heladero! Me puso  
casi todo de americana!



$d_2$


@mary\_de\_recoleta  
Muy **buena** peliiii,  
Las **quiero** amiguiis!



...

$d_n$

@señor\_de\_la\_plaza76  
Mi Vieja mula ya  
no es lo que era



## Quiero predecir

$d$

@juanma25  
Que bien que estoy!

$c_{MAP} = ?$

# Naïve Bayes

$$\begin{aligned} c_{MAP} &= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(d|c)P(c) \\ &= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(x_1, x_2, x_3, \dots, x_m | c)P(c) \end{aligned}$$

Difícil de  
estimar



estimación


$$\frac{\#c}{\#D}$$



## Set de entrenamiento

$d_1$

@nos\_paso\_a\_todos  
**Odio** al heladero! Me puso  
casi todo de americana!

$c_1 =$  

$d_2$


@mary\_de\_recoleta  
Muy **buena** peliiii,  
Las **quiero** amiguiis!

$c_2 =$  

...

$d_n$

@señor\_de\_la\_plaza76  
Mi Vieja mula ya  
no es lo que era

$c_n =$  

## Quiero predecir

$d$

@juanma25  
Que bien que estoy!

$c_{MAP} = ?$



# Naïve Bayes

$$\begin{aligned}
 c_{MAP} &= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(d|c)P(c) \\
 &= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(x_1, x_2, x_3, \dots, x_m | c)P(c)
 \end{aligned}$$

Difícil de  
estimar

estimación

$$\frac{\#c}{\#D}$$

## Multinomial Naïve Bayes approximation

- **Bag of words:** La posición de las palabras no importa
- **Independencia Condicional:**  $P(x_i|c)$  son independientes


$$P(x_1, x_2, \dots, x_m | c) = P(x_1 | c) \cdot P(x_2 | c) \dots P(x_m | c)$$

$$P(x_1, x_2, \dots, x_m | c) = P(Que|c)P(bien|c)P(que|c)P(estoy|c)P(!|c)$$

## Set de entrenamiento

$d_1$

@nos\_paso\_a\_todos  
**Odio** al heladero! Me puso  
casi todo de americana!

$c_1 =$  

$d_2$


@mary\_de\_recoleta  
Muy **buena** peliiii,  
Las **quiero** amiguiis!

$c_2 =$  

...

$d_n$

@señor\_de\_la\_plaza76  
Mi Vieja mula ya  
no es lo que era

$c_n =$  

## Quiero predecir

$d$

@juanma25  
Que bien que estoy!

$c_{MAP} = ?$

# Multinomial Naïve Bayes

$$\begin{aligned}c_{MNB} &= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(x_1|c)P(x_2|c)\dots P(x_m|c)P(c) \\ &= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(c) \prod_i P(x_i|c)\end{aligned}$$

# Estimations

$$\begin{aligned}c_{MNB} &= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(x_1|c)P(x_2|c)\dots P(x_m|c)P(c) \\ &= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(c) \prod_i P(x_i|c)\end{aligned}$$

$$\hat{P}(c) = \frac{N_c}{N_{doc}}$$

Fracción del training set con clase  $c$

$$\hat{P}(w_i|c) = \frac{\operatorname{count}(w_i, c)}{\sum_{w \in V} \operatorname{count}(w, c)}$$

Fracción de apariciones de la palabra  $w_i$  entre todas las palabras de los documentos de clase  $c$

**Bolsa de palabras de todos los documentos de clase  $c$**

Palabras	Frec.
a	1921
arriba	121
....	
zebra	3


# Ejemplo


$$\hat{P}(c) = \frac{N_c}{N_{doc}}$$


$$\hat{P}(w_i|c) = \frac{\text{count}(w_i, c)}{\sum_{w \in V} \text{count}(w, c)}$$

$$c_{MNB} = \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(x_1|c)P(x_2|c)\dots P(x_m|c)P(c)$$

$$= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(c) \prod_i P(x_i|c)$$

$d_1$  Estoy feliz  $c_1 =$  

$d_2$  Estoy triste y mojado  $c_2 =$  

$d_3$  Estoy triste y con hambre  $c_3 =$  

$d_{test}$  estoy con hambre  $c_{test} =$  ?

$$P(neg|d_{test}) \propto P(neg) [P(estoy|neg)P(hambre|neg)]$$


# Ejemplo


$$\hat{P}(c) = \frac{N_c}{N_{doc}}$$


$$\hat{P}(w_i|c) = \frac{\text{count}(w_i, c)}{\sum_{w \in V} \text{count}(w, c)}$$

$$c_{MNB} = \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(x_1|c)P(x_2|c)\dots P(x_m|c)P(c)$$

$$= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(c) \prod_i P(x_i|c)$$

$d_1$  Estoy feliz  $c_1 =$  

$d_2$  Estoy triste y mojado  $c_2 =$  

$d_3$  Estoy triste y con hambre  $c_3 =$  

$d_{test}$  estoy con hambre  $c_{test} =$  ?

$$P(neg|d_{test}) \propto P(neg) [P(estoy|neg)P(hambre|neg)]$$

$$\propto \frac{2}{3} \left[ \begin{array}{c} \\ \end{array} \right]$$


# Ejemplo


$$\hat{P}(c) = \frac{N_c}{N_{doc}}$$


$$\hat{P}(w_i|c) = \frac{count(w_i, c)}{\sum_{w \in V} count(w, c)}$$

BoW de todos los documentos de clase *neg*

Palabras	Frec.
estoy	2
triste	2
mojado	1
hambre	1

$d_1$  Estoy feliz  $c_1 =$  

$d_2$  Estoy triste y mojado  $c_2 =$  

$d_3$  Estoy triste y con hambre  $c_3 =$  

$d_{test}$  estoy con hambre  $c_{test} =$  ?


$$P(neg|d_{test}) \propto P(neg) [P(estoy|neg)P(hambre|neg)]$$


$$\propto \frac{2}{3} \begin{bmatrix} \quad \end{bmatrix}$$


# Ejemplo

$$\hat{P}(c) = \frac{N_c}{N_{doc}}$$

$$\hat{P}(w_i|c) = \frac{count(w_i, c)}{\sum_{w \in V} count(w, c)}$$

$d_1$  Estoy feliz  $c_1 =$  

$d_2$  Estoy triste y mojado  $c_2 =$  

$d_3$  Estoy triste y con hambre  $c_3 =$  

$d_{test}$  estoy con hambre  $c_{test} =$  ?

BoW de todos los documentos de clase *neg*

Palabras	Frec.
estoy	2
triste	2
mojado	1
hambre	1


$$P(neg|d_{test}) \propto P(neg) [P(estoy|neg)P(hambre|neg)]$$


$$\propto \frac{2}{3} \left[ \frac{2}{6} \cdot \frac{1}{6} \right] = \frac{1}{27}$$


# Ejemplo

$$\hat{P}(c) = \frac{N_c}{N_{doc}}$$

$$\hat{P}(w_i|c) = \frac{count(w_i, c)}{\sum_{w \in V} count(w, c)}$$

$d_1$  Estoy feliz  $c_1 =$  

$d_2$  Estoy triste y mojado  $c_2 =$  

$d_3$  Estoy triste y con hambre  $c_3 =$  

$d_{test}$  estoy con hambre  $c_{test} =$  ?

BoW de todos los documentos de clase *neg*

Palabras	Frec.
estoy	2
triste	2
mojado	1
hambre	1

BoW de todos los documentos de clase *pos*

Palabras	Frec.
estoy	1
feliz	1

$$P(neg|d_{test}) \propto P(neg) [P(estoy|neg)P(hambre|neg)]$$

$$\propto \frac{2}{3} \left[ \frac{2}{6} \cdot \frac{1}{6} \right] = \frac{1}{27}$$


$$P(pos|d_{test}) \propto P(pos) [P(estoy|pos)P(hambre|pos)]$$





# Ejemplo

$$\hat{P}(c) = \frac{N_c}{N_{doc}}$$

$$\hat{P}(w_i|c) = \frac{count(w_i, c)}{\sum_{w \in V} count(w, c)}$$

$d_1$  Estoy feliz  $c_1 =$  

$d_2$  Estoy triste y mojado  $c_2 =$  

$d_3$  Estoy triste y con hambre  $c_3 =$  

$d_{test}$  estoy con hambre  $c_{test} =$  ?

BoW de todos los documentos de clase *neg*

Palabras	Frec.
estoy	2
triste	2
mojado	1
hambre	1

BoW de todos los documentos de clase *pos*

Palabras	Frec.
estoy	1
feliz	1

$$P(neg|d_{test}) \propto P(neg) [P(estoy|neg)P(hambre|neg)]$$

$$\propto \frac{2}{3} \left[ \frac{2}{6} \cdot \frac{1}{6} \right] = \frac{1}{27}$$

$$P(pos|d_{test}) \propto P(pos) [P(estoy|pos)P(hambre|pos)]$$

$$\propto \frac{1}{3} \left[ \frac{1}{2} \cdot 0 \right] = 0$$

# Laplace (add-1) smoothing

$$\begin{aligned}\hat{P}(w_i|c) &= \frac{\text{count}(w_i,c)+1}{\sum_{w \in V} \text{count}(w,c)+1} \\ &= \frac{\text{count}(w_i,c)+1}{\left[ \sum_{w \in V} \text{count}(w,c) \right] + |V|}\end{aligned}$$

## add- $\alpha$ smoothing

$$\begin{aligned}\hat{P}(w_i|c) &= \frac{\text{count}(w_i,c)+\alpha}{\sum_{w \in V} \text{count}(w,c)+\alpha} \\ &= \frac{\text{count}(w_i,c)+\alpha}{\left[ \sum_{w \in V} \text{count}(w,c) \right] + \alpha|V|}\end{aligned}$$

Bolsa de palabras de todos los documentos de clase  $c$

Palabras	Frec.
a	1921+1
arriba	121+1
....	
zebra	3+1

Palabras	Frec.
a	1921 + $\alpha$
arriba	121 + $\alpha$
....	
zebra	3 + $\alpha$

# Ejercicio: ahora con smoothing ( $\alpha=0.1$ )

$$\hat{P}(c) = \frac{N_c}{N_{doc}}$$


$$\hat{P}(w_i|c) = \frac{count(w_i, c) + \alpha}{\left[ \sum_{w \in V} count(w, c) \right] + \alpha|V|}$$


neg


Palabras	Frec.
estoy	2
triste	2
mojado	1
hambre	1

pos

Palabras	Frec.
estoy	1
feliz	1

$d_1$  Estoy feliz  $c_1 =$  

$d_2$  Estoy triste y mojado  $c_2 =$  

$d_3$  Estoy triste y con hambre  $c_3 =$  

$d_{test}$  estoy con hambre  $c_{test} =$  ?

$$P(neg|d_{test}) \propto P(neg) [P(estoy|neg)P(hambre|neg)]$$

$\propto$

$$P(pos|d_{test}) \propto P(pos) [P(estoy|pos)P(hambre|pos)]$$

$\propto$

# Ahora con smoothing ( $\alpha=0.1$ )

$$\hat{P}(c) = \frac{N_c}{N_{doc}}$$


$$\hat{P}(w_i|c) = \frac{count(w_i, c) + \alpha}{\left[ \sum_{w \in V} count(w, c) \right] + \alpha|V|}$$


neg


Palabras	Frec.
estoy	2
triste	2
mojado	1
hambre	1

pos

Palabras	Frec.
estoy	1
feliz	1

$d_1$  Estoy feliz  $c_1 =$  

$d_2$  Estoy triste y mojado  $c_2 =$  

$d_3$  Estoy triste y con hambre  $c_3 =$  

$d_{test}$  estoy con hambre  $c_{test} =$  ?

$$P(neg|d_{test}) \propto P(neg) [P(estoy|neg)P(hambre|neg)]$$

$$\propto \frac{2}{3} \left[ \frac{2.1}{6.4} \cdot \frac{1.1}{6.4} \right] \approx 0,038$$

$$P(pos|d_{test}) \propto P(pos) [P(estoy|pos)P(hambre|pos)]$$

$\propto$

# Ahora con smoothing ( $\alpha=0.1$ )

$$\hat{P}(c) = \frac{N_c}{N_{doc}}$$


$$\hat{P}(w_i|c) = \frac{count(w_i, c) + \alpha}{\left[ \sum_{w \in V} count(w, c) \right] + \alpha|V|}$$


neg


Palabras	Frec.
estoy	2
triste	2
mojado	1
hambre	1

pos

Palabras	Frec.
estoy	1
feliz	1

$d_1$  Estoy feliz  $c_1 =$  

$d_2$  Estoy triste y mojado  $c_2 =$  

$d_3$  Estoy triste y con hambre  $c_3 =$  

$d_{test}$  estoy con hambre  $c_{test} =$  ?

$$P(neg|d_{test}) \propto P(neg) [P(estoy|neg)P(hambre|neg)]$$

$$\propto \frac{2}{3} \left[ \frac{2.1}{6.4} \cdot \frac{1.1}{6.4} \right] \approx 0,038$$

$$P(pos|d_{test}) \propto P(pos) [P(estoy|pos)P(hambre|pos)]$$

$$\propto \frac{1}{3} \left[ \frac{1.1}{2.2} \cdot \frac{0.1}{2.2} \right] \approx 0,008$$

# Problemas numéricos

$$\begin{aligned}c_{MNB} &= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(x_1|c)P(x_2|c) \dots P(x_m|c)P(c) \\ &= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(c) \prod_i P(x_i|c)\end{aligned}$$

La productoria de muchos números muy chicos da un número muy muy muy chico

# Problemas numéricos

$$\begin{aligned}c_{MNB} &= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(x_1|c)P(x_2|c) \dots P(x_m|c)P(c) \\ &= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} P(c) \prod_i P(x_i|c)\end{aligned}$$

La productoria de muchos números muy chicos da un número muy muy muy chico

Solución:

La clase con mayor probabilidad, también tendrá mayor  $\log(\text{probabilidad})$

$$\begin{aligned}c_{MNB} &= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} \log[P(c) \prod_i P(x_i|c)] \\ &= \underset{c \in C = \{pos, neg\}}{\operatorname{argmax}} \log P(c) + \sum_i \log P(x_i|c)\end{aligned}$$

# Tips

Cómo mejorar (o quizás no ) un sistema de clasificación de texto:

➤ **Normalización:**

- Colapso de tokens (números, fechas, nombres)



# Tips

Cómo mejorar (o quizás no ) un sistema de clasificación de texto:

➤ **Normalización:**

- Colapso de tokens (números, fechas, nombres)
- **Lematizar** o hacer **stemming**

➤ **Aumentar** el peso de ciertos tokens (duplicar tokens):

- Tokens del título (Cohen & Singer 1996)
- Primera oración de cada párrafo (Murata, 1999)
- En oraciones que contienen palabras del título (Ko, 2002)

# Tips

- Se pueden descartar las palabras muy **poco frecuentes** o las **muy frecuentes**

,  
,  
,  
,

# Tips


- Se pueden descartar las palabras muy **poco frecuentes** o las **muy frecuentes**
- Se pueden descartar **stopwords** (“de”, “la”, “los”, “que”,...)

# Tips

- Se pueden descartar las palabras muy **poco frecuentes** o las **muy frecuentes**
- Se pueden descartar **stopwords** (“de”, “la”, “los”, “que”,...)
- Para el *sentiment analysis* se pueden **propagar negaciones**

Por ejemplo:

Esto no está bueno ni rico. En la casa de...



Esto no no\_está no\_bueno no\_ni no\_rico En la casa de...

# Tips

- Se pueden extraer n-gramas

**“Esto no está bueno ni rico.”**

- Unigramas:

[“Esto”, “no”, “está”, “bueno”, “ni”, “rico”, “.”]

- Bigramas:

[“Esto no”, “no está”, “está bueno”, “bueno ni”, “ni rico”, “rico .”]

- Trigramas:

[“Esto no está”, “no está bueno”, “está bueno ni”, ...]

# Clasificación de Textos

Naïve Bayes:

- No tiende a over-fitear, high-bias, (Ng and Jordan, 2002)
- No tiene muchos parámetros a ajustar
- Es intuitivo
- Es rapido

# Clasificación de Textos

Naïve Bayes:


- No tiende a over-fitear, high-bias, (Ng and Jordan, 2002)
- No tiene muchos parámetros a ajustar
- Es intuitivo
- Es rapido

Pero:

- Es un primer algoritmo a probar, es probable que otros métodos de clasificación supervisada funcionen mejor, como: SVM, NNs

# Detección de hate speech en twitter

## Train set



80% del dataset

## Test set



20% del dataset



# Evaluación de los métodos

Identificación de mensajes con hate speech:  
Sobre el test set

	Eran <i>hate</i>	Eran <i>no-hate</i>
Identificados como <i>hate</i>	8 (tp)	8 (fp)
Identificados como <i>no-hate</i>	2 (fn)	92 (tn)

Matriz de confusión

Notar que estoy evaluando la capacidad de identificar los posts de **hate**, y no la capacidad de identificar los de **no-hate**

# Precision y Recall

**Precision:** fracción de los identificados como *hate* que fueron correctamente clasificados

**Recall:** fracción de los que eran *hate*, que efectivamente fueron identificados como *hate*

	Eran <i>hate</i>	Eran no- <i>hate</i>
Identificados como <i>hate</i>	8 (tp)	8 (fp)
Identificados como no- <i>hate</i>	2 (fn)	92 (tn)

$$Precision = \frac{tp}{tp+fp} = \frac{8}{16} \approx 0.5$$

$$Recall = \frac{tp}{tp+fn} = \frac{8}{10} \approx 0.8$$

# Precision y Recall

## Casos límites:

Clasifico siempre como *hate*

	Eran <i>hate</i>	Eran <i>no-hate</i>
Identificados como <i>hate</i>	10 (tp)	100 (fp)
Identificados como <i>no-hate</i>	0 (fn)	0 (tn)

$$Precision = \frac{tp}{tp+fp} = \frac{10}{110} \approx 0.09$$

$$Recall = \frac{tp}{tp+fn} = \frac{10}{10} \approx 1$$

Clasifico como *hate* solo si estoy muuuy seguro

	Eran <i>hate</i>	Eran <i>no-hate</i>
Identificados como <i>hate</i>	3 (tp)	1 (fp)
Identificados como <i>no-hate</i>	7 (fn)	99 (tn)

$$Precision = \frac{tp}{tp+fp} = \frac{3}{4} \approx 0.75$$

$$Recall = \frac{tp}{tp+fn} = \frac{3}{10} \approx 0.3$$

# F-measure

El F-measure (F1-score) es un trade off entre el Precision y el Recall y se calcula como el promedio armónico entre ambos

$$F = \frac{2}{\frac{1}{P} + \frac{1}{R}} = \frac{2PR}{P+R}$$

$$\textit{Precision} = \frac{tp}{tp+fp} = \frac{8}{16} \approx 0.5$$

$$\textit{Recall} = \frac{tp}{tp+fn} = \frac{8}{10} \approx 0.8$$

$$\longrightarrow F = 0.616$$

# Macro vs Micro averaging

Cuando no hay una clase privilegiada

	Eran bot	Eran troll	Eran normal
Clasif: bot	10	20	0
Clasif: troll	10	40	0
Clasif: normal	0	0	1000

bot	eran pos	eran neg
Clasif: pos	10 (tp)	20 (fp)
Clasif: neg	10 (fn)	1040 (tn)

troll	eran pos	eran neg
Clasif: pos	40 (tp)	10 (fp)
Clasif: neg	20 (fn)	1010 (tn)

normal	eran: pos	eran: neg
Clasif: pos	1000 (tp)	0 (fp)
Clasif: neg	0 (fn)	80 (tn)

# Macro vs Micro averaging

crisis	eran pos	eran neg
Clasif: pos	10 (tp)	20 (fp)
Clasif: neg	10 (fn)	1040 (tn)

precision = 0.5

red	eran pos	eran neg
Clasif: pos	40 (tp)	10 (fp)
Clasif: neg	20 (fn)	1010 (tn)

precision = 0.67

green	eran: pos	eran: neg
Clasif: pos	1000 (tp)	0 (fp)
Clasif: neg	0 (fn)	80 (tn)

precision = 1

**Macro-averaging precision =  $(0.5 + 0.67 + 1)/3 = 0.72$**

# Macro vs Micro averaging

crisis	eran pos	eran neg
Clasif: pos	10 (tp)	20 (fp)
Clasif: neg	10 (fn)	1040 (tn)

precision = 0.5

red	eran pos	eran neg
Clasif: pos	40 (tp)	10 (fp)
Clasif: neg	20 (fn)	1010 (tn)

precision = 0.67

green	eran: pos	eran: neg
Clasif: pos	1000 (tp)	0 (fp)
Clasif: neg	0 (fn)	80 (tn)

precision = 1

**Macro-averaging precision =  $(0.5 + 0.67 + 1)/3 = 0.72$**

---


## Micro-averaging table

Total	eran pos	eran neg
Clasif: pos	1050 (tp)	30 (fp)
Clasif: neg	30 (fn)	2130 (tn)


**Micro-averaging precision =  $1050/1080=0.97$**

# Training - Evaluation sets

Training set  
80%



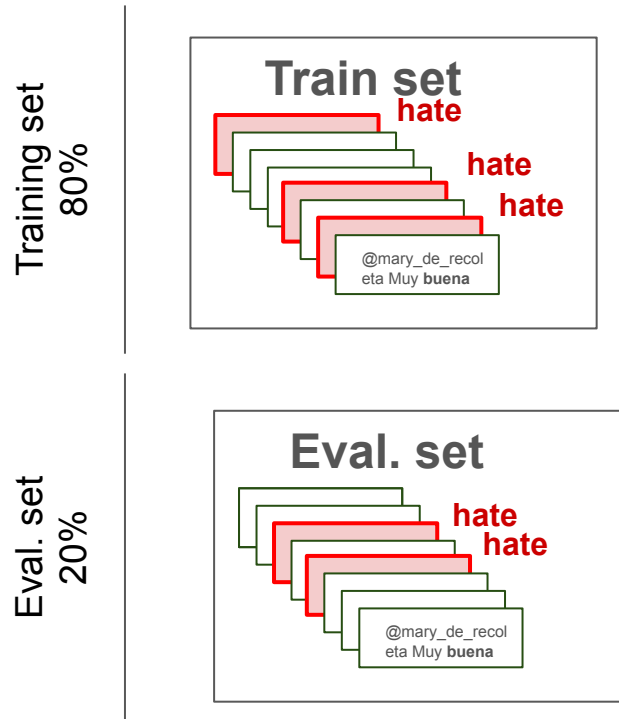
Eval. set  
20%



Opción 1

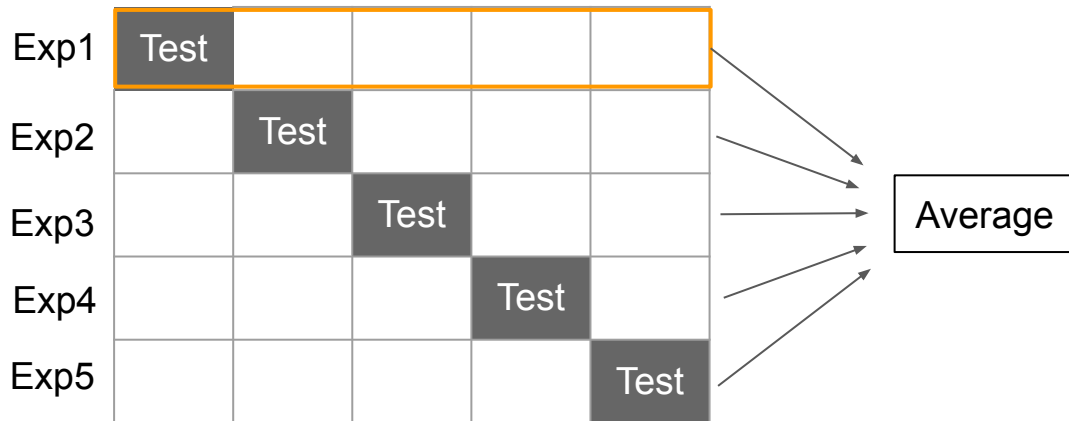


# Cross Validation (5-fold CV)



Opción 1


## 5-Fold Cross-Validation



Opción 2

# Y si quiero probar muchos modelos?

Evalúo muchos modelos y elijo el mejor



## Modelos

1) f-score=0.56

2) f-score=0.61

...

**351) f-score=0.83**


...

9581) f-score=0.59

9582) f-score=0.66

# Y si quiero probar muchos modelos?

Evalúo muchos modelos y elijo el mejor



## Modelos

1) f-score=0.56

2) f-score=0.61

...

**351) f-score=0.83**

...

9581) f-score=0.59

9582) f-score=0.66




# Y si quiero probar muchos modelos?

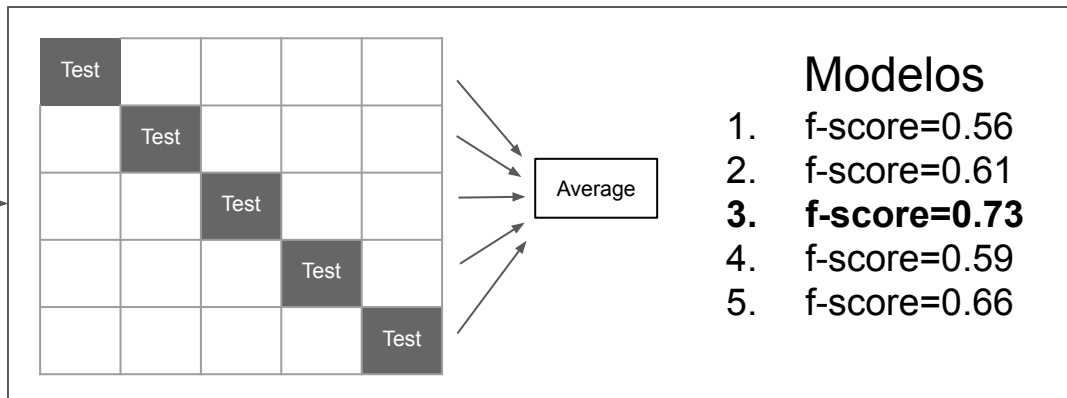
Training set  
80%



Test. set  
20%



Evalúo muchos modelos y elijo el mejor



# Cross Validation + Test set

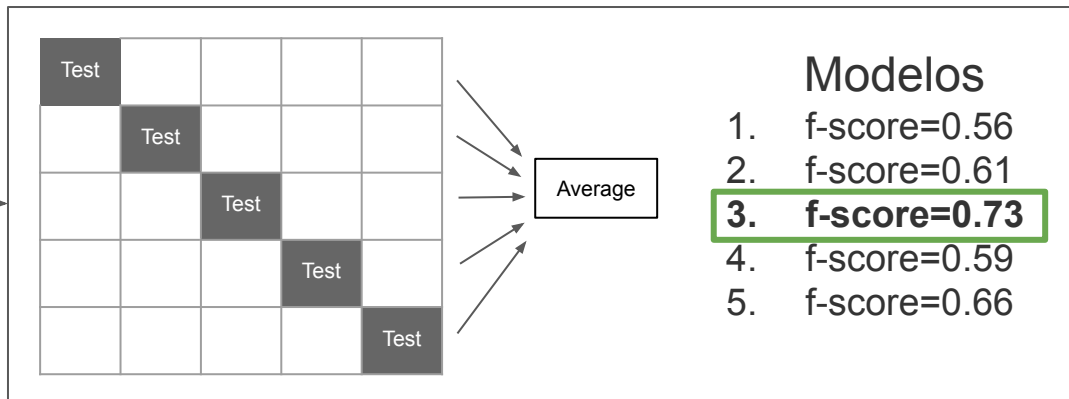
Training set  
80%



Test. set  
20%



Evalúo muchos modelos y elijo el mejor



Modelo 3 entrenado  
con el Train set

**f-score=0.70**

**FIN**